

# Computação aplicada - Inteligência computacional

## **Deteccção de perdas não técnicas em sistemas de distribuição de energia e análise de desempenho entre modelos de aprendizagem de máquina utilizando dados de vizinhança**

Universidade Federal do Pará (UFPA).

Instituto de Tecnologia (ITEC).

Programa de Pós-graduação em engenharia elétrica (PPGEE).

Orientador: Marcelino Silva da Silva.

Coorientador: Roberto Célio Limão de Oliveira.

Discente: Thiago Furtado Ferreira.

### **Objetivo da modelagem**

Determinar quais consumidores de energia elétrica possuem defeito na medição sejam por natureza técnica do equipamento ou por fraude proposital e consumidores que estão com medição normal.

A base de dados foi processada com normalização MIN-MAX, 200 variáveis de entrada, 1 de target e outra de ID, totalizando 202 variáveis.

O target possui 2 classes, 0 e 1, sendo:

- 0 - Consumidores que foram fiscalizados e que não possuíam fraude ou defeito na medição.
- 1 - Consumidores fiscalizados que possuíam fraude ou defeito na medição.

A base de dados foi gerada com restrições com finalidade de limpar os dados.

- Foram considerados somente os consumidores de baixa tensão (BT).
- Consumidores BT com ligação em média tensão foram removidos, pois seu consumo é comparável com um consumidor AT (Alta tensão).
- Pontos de medição fora dos limites da área de concessão da concessionária de energia foram removidos, informações baseadas nas coordenadas geográficas dos pontos de medição.
- Consumidores BT com consumo mensal maior ou igual a 20000 KWH foram removidos.
- Registros com valores nulos foram removidos.
- Registros com consumo negativo foram removidos.
- Removidas todos os registros com data de ligação superior ao dia atual de apuração.

A partir dos dados de coordenadas dos consumidores foi feito um processamento para verificar quais outros consumidores estavam dentro de um determinado raio para geração de outras variáveis dos vizinhos que a base de dados original não contempla.

- O raio considerado foi 30 metros do ponto de medição do consumidor.
- Número de fraudes, número de fiscalizações, total de inspeções normais, consumo máximo, consumo mínimo, quantidade total de consumos mínimos da fase em 24 meses, fraudes exclusivas por cliente, quantidade de pontos de medição no raio.
- Consumidores com mais de 250 pontos de medição vizinho no raio de 30 metros foram descartados.

## **Da divisão das bases de dados**

Os dados foram divididos em 5 bases, sendo:

- Uma base de dados para treinamento balanceada, com 50 mil registros, 25 mil normais e 25 mil fraude.
- Uma base de dados para score do modelo balanceada com 43396 registros no total.
- Uma base balanceada para validação cruzada com 11572 registros.
- Uma base balanceada para teste do modelo com 17358 registros.
- Uma base para teste desbalanceada positiva com 11163 registros, sendo 92% dos registros de fraude e 8% de normais.
- Uma base para teste desbalanceada negativa com 11163 registros, sendo 92% dos registros normais e 8% com fraude.

***Nenhum dos registros se repete em nenhuma das bases.***

## **Importação das bibliotecas**

In [1]:

```
1
2 #####
3 #####
4 import pandas as pd
5 import numpy as np
6 from datetime import datetime
7 import string
8 import os
9 from sklearn.model_selection import cross_val_score as validacaoCruzada
10 from sklearn.metrics import confusion_matrix as matrizConfusao
11 from sklearn.model_selection import cross_val_score
12 from sklearn.metrics import accuracy_score
13 from sklearn.tree import export_graphviz
14 from sklearn import preprocessing
15 import seaborn as sn
16 import matplotlib.pyplot as plt
17 from sklearn.naive_bayes import GaussianNB
18 from sklearn.ensemble import RandomForestClassifier
19 from sklearn.neural_network import MLPClassifier
20 from sklearn.tree import DecisionTreeClassifier
21 from sklearn import tree
22 from sklearn.cluster import KMeans
23 from sklearn.svm import SVC
24 from sklearn import metrics
25 from sklearn.metrics import roc_auc_score
26 from sklearn.model_selection import validation_curve
27 #####
28 #####
29 ### Configurações para baixar dados do Google Drive
30 from pydrive.auth import GoogleAuth
31 from pydrive.drive import GoogleDrive
32 #from google.colab import auth
33 #from google.colab import files
34 #from oauth2client.client import GoogleCredentials
35 #auth.authenticate_user()
36 #gauth = GoogleAuth()
37 #gauth.credentials = GoogleCredentials.get_application_default()
38 #drive = GoogleDrive(gauth)
39 import logging
40 logging.getLogger('googleapiclient.discovery_cache').setLevel(logging.ERROR)
41 #####
```

```

42 #####
43 ### Variaveis globais
44 resultadoValidacaoCruzada=""
45 vp=0
46 vn=0
47 fp=0
48 fn=0
49 vetorResultadoTeste=[];
50 vetorResultadoCV=[];
51 vetorScore=[];
52 vetorMSETeste=[];
53 #####
54 #####
55 ### Função para gravar log e exibir mensagens em tela
56 def m(conteudo, exibir):
57     hora = datetime.now()
58     hora = hora.strftime("%d/%m/%Y_%H:%M:%S")
59
60 #     from google.colab import files
61 #     with open(caminhoArquivoLog, 'a') as f:
62 #         conteudo_ = "[" + hora + "]: " + conteudo
63 #         f.write(conteudo_ + " \n")
64 #     f.close()
65 #     if exibir == 1:
66 #         print(conteudo_)
67
68 #####
69 #####
70 ### Arquivos de dados
71 #LISTA OS ARQUIVOS DA PASTA DO GOOGLE DRIVE
72 #file_list = drive.ListFile({'q': "'1EintRF9-o9c0nKiNVKedXXSq7-I4Vvj2' in parents and trashed=false"}).GetList()
73 ##for file1 in file_list:
74 #     print('title: %s, id: %s' % (file1['title'], file1['id']))
75 #####
76 #####
77 ### Gera Histograma
78 def geraHistograma(dtHistograma, caption):
79     dtHistograma_=dtHistograma['TARGET']
80     dtHistograma_=dtHistograma_.to_numpy()
81     histograma=pd.DataFrame(dtHistograma_, columns = [caption])
82     histograma.hist(bins=3)
83     # pc()

```

```
In [2]: 1 d=4
        2 print(d)
```

4

```
In [3]: 1 dtTreino = pd.read_excel(r'C:\Users\Computador\Documents\dadosExecucaoLocal\A50000k_TREINO_NORMALIZADA.xlsx', sheet_r
        2 #geraHistograma(dtTreino, 'Histograma do Target da base de Treino')
        3 dtScore = pd.read_excel(r'C:\Users\Computador\Documents\dadosExecucaoLocal\B43396k_SCORE_NORMALIZADA.xlsx', sheet_nam
        4 #geraHistograma(dtScore, 'Histograma do Target da base de Score')
        5 dtValidacao = pd.read_excel(r'C:\Users\Computador\Documents\dadosExecucaoLocal\C11572K_VALIDACAO_NORMALIZADA.xlsx', s
        6 #geraHistograma(dtValidacao, 'Histograma do Target da base de Validação')
        7 dtTeste = pd.read_excel(r'C:\Users\Computador\Documents\dadosExecucaoLocal\C17358K_TESTE_NORMALIZADA.xlsx', sheet_nam
        8 #geraHistograma(dtTeste, 'Histograma do Target da base de Teste')
        9 dtTestePositivo = pd.read_excel(r'C:\Users\Computador\Documents\dadosExecucaoLocal\A11163_DESBALANCO_POSITIVO_NORMALI
       10 #geraHistograma(dtTestePositivo, 'Histograma do Target da base de Teste Positivo. 92% positivo e 8% negativo')
       11 dtTesteNegativo = pd.read_excel(r'C:\Users\Computador\Documents\dadosExecucaoLocal\A11163_DESBALANCO_NEGATIVO_NORMALI
       12 #geraHistograma(dtTesteNegativo, 'Histograma do Target da base de Teste Negativo. 92% negativo e 8% positivo.')
       13
```

**Carrega os dados**

In [5]:

```
1  ### Função para computar os resultados da validação cruzada
2  def exibeResultados(scores, exibir=1):
3      if (exibir==1):
4          contador=0
5          for score in scores:
6              print("Score "+ str(contador) +": " + str(score))
7              contador=contador+1
8          print("Máximo: " + str(scores.max()))
9          print("Mínimo: " + str(scores.min()))
10         print("Média: " + str(scores.mean()))
11         print("Desv. Padrão: " + str(scores.std()))
12         %%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%
13         %%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%
14     ### ETL - Ajuste de dados
15     #Separa os dados de target dos demais dados de entrada
16     yTreino = dtTreino['TARGET']
17     XTreino = dtTreino.drop(['INSTALACAO','TARGET', 'REINCIDENCIA'],axis=1)
18
19     yScore = dtScore['TARGET']
20     XScore = dtScore.drop(['INSTALACAO','TARGET', 'REINCIDENCIA'],axis=1)
21
22     yValidacao = dtValidacao['TARGET']
23     XValidacao = dtValidacao.drop(['INSTALACAO','TARGET', 'REINCIDENCIA'],axis=1)
24
25     yTeste = dtTeste['TARGET']
26     XTeste = dtTeste.drop(['INSTALACAO','TARGET', 'REINCIDENCIA'],axis=1)
27
28     yTestePositivo = dtTestePositivo['TARGET']
29     XTestePositivo = dtTestePositivo.drop(['INSTALACAO','TARGET', 'REINCIDENCIA'],axis=1)
30
31     yTesteNegativo = dtTesteNegativo['TARGET']
32     XTesteNegativo = dtTesteNegativo.drop(['INSTALACAO','TARGET', 'REINCIDENCIA'],axis=1)
33     %%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%
34     %%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%
35     ### Gera gráficos, Matriz de confusão e ROC-UAC
36     def geraGraficos(vp_, vn_, fp_, fn_, yReal__, yModelo__, titulo__):
37         #GERA MATRIZ DE CONFUSAO
38         array = [[vp_,fp_],[fn_,vn_]]
39         df_cm = pd.DataFrame(array,index =['FRAUDE', 'NORMAL'], columns = ['FRAUDE', 'NORMAL'])
40         ax=sn.heatmap(df_cm, annot=True, annot_kws={"size": 16}, fmt="d", cbar=False)
41         ax.set_title('Matriz de confusão ' + titulo__, weight="bold")
```

```

42 plt.xlabel('Real', weight="bold", size=18)
43 plt.ylabel('Modelo',weight="bold", size=18)
44 plt.figure(figsize = (5,3))
45 plt.show()
46
47
48 #GERA ROC-UAC
49 yReal__ = np.array(yReal__)
50 yModelo__ = np.array(yModelo__)
51 roc_auc_score(yReal__, yModelo__)
52 fpr, tpr, _ = metrics.roc_curve(yReal__, yModelo__)
53 auc = metrics.roc_auc_score(yReal__, yModelo__)
54 ax2=plt.plot(fpr,tpr,label="AUC = "+str(auc))
55 plt.title('Curva ROC ' + titulo__)
56 plt.legend(loc=4)
57 plt.show()
58
59 return auc
60 #####
61 #####
62 ## Converte para Array
63 #Converte os dataFrames com os dados carregados para array NumPy.
64
65 XTreino=XTreino.to_numpy()
66 yTreino=yTreino.to_numpy()
67
68 XScore=XScore.to_numpy()
69 yScore=yScore.to_numpy()
70
71 XValidacao=XValidacao.to_numpy()
72 yValidacao=yValidacao.to_numpy()
73
74 XTeste=XTeste.to_numpy()
75 yTeste=yTeste.to_numpy()
76
77 XTestePositivo=XTestePositivo.to_numpy()
78 yTestePositivo=yTestePositivo.to_numpy()
79
80 XTesteNegativo=XTesteNegativo.to_numpy()
81 yTesteNegativo=yTesteNegativo.to_numpy()
82 #####
83 #####

```

```

84 ### Adiciona resultados dos teste ao vetor final para exportar
85 def addExportar(metrica__, valor__, algoritmo__, tipoTeste__):
86     global vetorResultadoTeste
87     resultadosProcessados__=[metrica__, valor__, algoritmo__, tipoTeste__];
88     vetorResultadoTeste.append(resultadosProcessados__)
89     %%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%
90     %%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%
91     ## Adiciona os Score para o BloxPlot
92     def addBoxPlot(algoritmo__,score__):
93         global vetorResultadoCV
94         resultadosProcessados__=[algoritmo__,score__];
95         vetorResultadoCV.append(resultadosProcessados__)
96         %%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%
97         %%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%
98     ### Computa as métricas dos testes
99     #Além das métricas dos teste a função gera um arquivo txt com os dados.
100    def computaMetricas(apuracao, nomeAlgoritmo, nomeTeste):
101        acertos=apuracao['ACERTOS'].sum()
102        erros=apuracao['ERROS'].sum()
103        global vp
104        vp=apuracao['VP'].sum()
105        global vn
106        vn=apuracao['VN'].sum()
107        global fp
108        fp=apuracao['FP'].sum()
109        global fn
110        fn=apuracao['FN'].sum()
111
112        sensibilidade=vp/(vp+fn)
113        especificidade=vn/(fp+vn)
114        precisao=vp/(vp+fp)
115        acuracia=(vp+vn)/(vp+vn+fp+fn)
116        revocacao=vp/(vp+fn)
117        pontuacao_f1=vp/(vp+((fn+fp)/2))
118
119        addExportar('SENSIBILIDADE', float(sensibilidade), nomeAlgoritmo, nomeTeste)
120        addExportar('ESPECIFICIDADE', float(especificidade), nomeAlgoritmo, nomeTeste)
121        addExportar('PRECISAO', precisao, nomeAlgoritmo, nomeTeste)
122        addExportar('ACURACIA', acuracia, nomeAlgoritmo, nomeTeste)
123        addExportar('REVOCACAO', revocacao, nomeAlgoritmo, nomeTeste)
124        addExportar('PONTUACAO_F1', pontuacao_f1, nomeAlgoritmo, nomeTeste)
125        addExportar('VP', vp, nomeAlgoritmo, nomeTeste)

```



```
126 addExportar('VN', vn, nomeAlgoritmo, nomeTeste)
127 addExportar('FP', fp, nomeAlgoritmo, nomeTeste)
128 addExportar('FN', fn, nomeAlgoritmo, nomeTeste)
129 addExportar('TOTAL REGISTROS', vp+vn+fp+fn, nomeAlgoritmo, nomeTeste)
130 addExportar('ACERTOS', acertos, nomeAlgoritmo, nomeTeste)
131 addExportar('ERROS', erros, nomeAlgoritmo, nomeTeste)
132 #%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%
133 #%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%
134
```

## Funções com modelo

In [6]:

```
1  ### Executa Treino
2  def executaTreino mdl_treino):
3      # pi()
4      mdl_treino.fit(XTreino, yTreino)
5
6  ### Executa Score
7  def executaScore(mdl_score, nomeAlgoritmo):
8      score=mdl_score.score(XScore, yScore)
9      global vetorScore
10     vetorScore__=[nomeAlgoritmo, score];
11     vetorScore.append(vetorScore__)
12     return score
13
14 ### Executa Validação Cruzada
15 def executaValidacaoCruzada(mdl_validacaoCruzada, folds, metrica, nomeAlgoritmo__):
16     scores = validacaoCruzada(mdl_validacaoCruzada, XValidacao, yValidacao, cv=folds,scoring=metrica)
17     addBoxPlot(nomeAlgoritmo__, scores)
18     return scores.mean()
19
20 ### Executa Teste
21 def executaTeste(mdl_testar, xTeste__, yTeste__, nomeAlgoritmo, tipoTeste):
22     resultadoTeste=mdl_testar.predict(xTeste__)
23     dtResultadoTeste=pd.DataFrame(resultadoTeste)
24     dtTarget=pd.DataFrame(yTeste__)
25
26     dtExportar=pd.concat([dtTarget, dtResultadoTeste, (dtTarget==dtResultadoTeste)*1, (dtTarget!=dtResultadoTeste)*1, (
27     dtExportar.columns = ['TARGET', 'MODELO', 'ACERTOS','ERROS', 'VP', 'VN', 'FP','FN']
28     computaMetricas(dtExportar, nomeAlgoritmo, tipoTeste)
29     titulo= nomeAlgoritmo + ' ' + tipoTeste
30     uac=geraGraficos(vp,vn,fp, fn, yTeste__, resultadoTeste, titulo)
31     return uac
32
33 ## Função Principal
34 def funcMain(modelo, nome, folds__, metrica__):
35     from sklearn import preprocessing
36     XTesteAA=XTeste
37     XTestePositivoAA=XTestePositivo
38     XTesteNegativoAA=XTesteNegativo
39
40     executaTreino(modelo)
41     rs_vc=executaValidacaoCruzada(modelo, folds__, metrica__, nome)
```

```
42
43     executaScore(modelo,nome)
44     uac1=executaTeste(modelo, XTesteAA, yTeste, nome, 'TESTE')
45     uac2=executaTeste(modelo, XTestePositivoAA, yTestePositivo, nome + '+', 'POSITIVO')
46     uac3=executaTeste(modelo, XTesteNegativoAA, yTesteNegativo, nome + '-', 'NEGATIVO')
47     print(rs_vc)
48     print(uac1)
49     print(uac2)
50     print(uac3)
51
```


## Parametros

```
In [1]: 1  nfoldscv=5
        2  tpMetricaCV='precision'
```

## 1-SVM

```
In [13]: 1 mdl_svm = SVC(C=1.0, kernel='poly', degree=5, gamma='scale', coef0=0.5, shrinking=True,
2           probability=False, tol=1e-03, cache_size=5000, class_weight=None, verbose=False,
3           max_iter=25000, decision_function_shape='ovr', random_state=None)
4
5 funcMain(mdl_svm, 'SVM', nfoldscv, tpMetricaCV)
```

c:\users\computador\anaconda3\lib\site-packages\sklearn\svm\base.py:244: ConvergenceWarning: Solver terminated early (max\_iter=25000). Consider pre-processing your data with StandardScaler or MinMaxScaler.  
% self.max\_iter, ConvergenceWarning)




## 2-KMEANS

### 2.1-Treinamento Kmeans

```
In [19]: 1 mdl_kmeans = KMeans(n_clusters=2, init='k-means++', n_init=10, max_iter=300, tol=0.0001,
2           precompute_distances='auto', verbose=0, random_state=None,
3           copy_x=True, n_jobs=None, algorithm='auto')
4
5
6 #funcMain(mdl_kmeans, 'KMEANS', nfoldscv, tpMetricaCV)
7
```

### 3-Random Forest


```
In [20]: 1 mdl_rndForest = RandomForestClassifier(n_estimators=500, criterion='entropy', max_depth=50, min_samples_split=2,
2                                             min_samples_leaf=1, min_weight_fraction_leaf=0.0, max_features='sqrt',
3                                             max_leaf_nodes=None, min_impurity_decrease=1e-09,
4                                             bootstrap=True, oob_score=False, n_jobs=None, random_state=None, verbose=0,
5                                             warm_start=False, class_weight=None)
6 funcMain(mdl_rndForest, 'RANDOM', n_foldsCV, tpMetricaCV)
```



<Figure size 360x216 with 0 Axes>

### 4-Decision Tree

```
In [22]: 1 mdl_decisionTree = tree.DecisionTreeClassifier(criterion='entropy', max_depth=300, splitter='best', min_impurity_decr
2 funcMain(mdl_decisionTree,'TREE', nfoldscv, tpMetricaCV)
```




<Figure size 360x216 with 0 Axes>

## 5-MLP


```
In [24]: 1 mdl_mlp = MLPClassifier(hidden_layer_sizes=(93), activation='relu',
2                               solver='adam', alpha=1e-04, batch_size='auto', learning_rate='constant',
3                               learning_rate_init=0.001, power_t=0.5, max_iter=350, shuffle=True, random_state=None, tol=1e-
4                               verbose=False, warm_start=False, momentum=0.9, nesterovs_momentum=True, early_stopping=False,
5                               validation_fraction=0.1, beta_1=0.9, beta_2=0.999, epsilon=1e-08, n_iter_no_change=10)
6 funcMain(mdl_mlp, 'MLP', nfoldsCV, tpMetricaCV)
```

```
c:\users\computador\anaconda3\lib\site-packages\sklearn\neural_network\multilayer_perceptron.py:562: ConvergenceWarni
ng: Stochastic Optimizer: Maximum iterations (350) reached and the optimization hasn't converged yet.
% self.max_iter, ConvergenceWarning)
c:\users\computador\anaconda3\lib\site-packages\sklearn\neural_network\multilayer_perceptron.py:562: ConvergenceWarni
ng: Stochastic Optimizer: Maximum iterations (350) reached and the optimization hasn't converged yet.
% self.max_iter, ConvergenceWarning)
c:\users\computador\anaconda3\lib\site-packages\sklearn\neural_network\multilayer_perceptron.py:562: ConvergenceWarni
ng: Stochastic Optimizer: Maximum iterations (350) reached and the optimization hasn't converged yet.
% self.max_iter, ConvergenceWarning)
c:\users\computador\anaconda3\lib\site-packages\sklearn\neural_network\multilayer_perceptron.py:562: ConvergenceWarni
ng: Stochastic Optimizer: Maximum iterations (350) reached and the optimization hasn't converged yet.
% self.max_iter, ConvergenceWarning)
```



## 6-Naive

```
In [8]: 1
2 mdl_naive=clf = GaussianNB(priors=None, var_smoothing=1e-17)
3 funcMain(mdl_naive,'NAIVE', nfoldscv, tpMetricaCV)
```



<Figure size 360x216 with 0 Axes>


## 7-Deep Learning



```
In [9]: 1 mdl_dl = MLPClassifier(hidden_layer_sizes=(400,400,400,400,400,400,400,400,400),
2                               activation='relu',
3                               solver='adam', alpha=1e-04, batch_size='auto', learning_rate='constant',
4                               learning_rate_init=1e-03, power_t=0.5, max_iter=350, shuffle=True, random_state=None, tol=1e-
5                               verbose=False, warm_start=False, momentum=0.9, nesterovs_momentum=True, early_stopping=False,
6                               validation_fraction=0.1, beta_1=0.9, beta_2=0.999, epsilon=1e-08, n_iter_no_change=10)
7 funcMain(mdl_dl,'DL', nfoldsCV, tpMetricaCV)
```

**Real**

<Figure size 360x216 with 0 Axes>



**Exporta os dados dos testes já realizados**

```
In [27]: 1 dtModelo=pd.DataFrame(vetorResultadoTeste)
2
3 dtModelo.columns = ['METRICA', 'VALOR', 'MODELO','TIPO_TESTE']
4 dataAtual= datetime.now()
5 dataAtual = dataAtual.strftime("_%d_%m_%Y_%H_%M_%S")
6 nomeArquivo__='E:\\resultados\\metricas'+ dataAtual +'.xlsx'
7 #from google.colab import files
8 dtModelo.to_excel(nomeArquivo__)
9 #files.download(nomeArquivo__)
10
```

## Gera BoxPlot da validação cruzada

```
In [ ]: 1 DT__=pd.DataFrame(vetorResultadoCV)
2 DT__.columns = ['MODELO','VALOR']
3 fig = plt.figure(figsize=(10, 10))
4 fig.suptitle('Comparação dos algoritmos CrossValidation')
5 ax = fig.add_subplot(111)
6 plt.boxplot(DT__['VALOR'])
7 ax.set_xticklabels(DT__['MODELO'])
8 plt.show()
```